Домашнє завдання 1

Кейс блоку 1 — «Structured Extraction Service»

> Побудуйте сервіс, який витягує структуровані дані із сирих текстів за схемою, порівнює провайдерську та локальну моделі й обґрунтовує вибір для продакшну. Орієнтовно 9 годин для виконання, 30 балів, дедлайн — **27.10 о 23:59.**

Сценарій і дані

Ви — AI-інженер, якому треба перетворити «брудні» тексти на валідний JSON за схемою та довести цифрами, яка модель і який промпт йдуть у продакшн. Це перший зріз вашого наскрізного курсового проєкту: далі ці дані та інтеграція з моделями стануть основою для RAG і агента.

Джерело текстів: дані вашого наскрізного проєкту (листи клієнтів, тікети, вакансії, описи товарів, технічні звіти) без персональних даних.

Мінімальний обсяг: 30 текстів, із них 10 розмічені вручну — це ваш **golden set**, за яким ви будете міряти якість. Тексти мають бути справді «брудними»: різна довжина, друкарські помилки, пропущені поля, змішані мови.

Кроки

Кейс ділиться на 4 кроки, кожен спирається на конкретне заняття. Кроки 1–2 здаються як чекпоінт до 24.10 у чат курсу **#ai-engineering-2-flood** (без балів, фідбек — на Q&A 26.10).

1. **Схема + baseline-промпт** (≈ 2 год, заняття 3)

- Опишіть схему (Pydantic або JSON Schema): не менше 6 полів, серед них щонайменше 1 enum і 1 вкладений об'єкт або список.
- Напишіть baseline-промпт і підключіть провайдерську модель через API зі structured output.
- Додайте retry і timeout; проженіть усі тексти та збережіть результати.

2. **Друга модель + заміри** (≈ 2 год, заняття 2–3)

- Підключіть локальну модель (Ollama або інша OSS) через спільний інтерфейс з першою.
- Винесіть параметри семплінгу (temperature, top_p) у конфіг і порівняйте щонайменше 2 конфігурації.
- Зміряйте для кожної моделі: точність по полях на golden set, % валідних відповідей, latency p50/p95, вартість на 1000 документів.

3. **Версіонування промптів і валідація** (≈ 3 год, заняття 4)

- Зберігайте промпти в окремих файлах з версією та changelog; потрібно щонайменше 2 версії з поясненням, що змінили і чому.
- Валідуйте кожну відповідь за схемою; невалідна — одна спроба виправлення, далі позначка failed.
- До кожного результату логуйте модель, версію промпту та параметри семплінгу.

4. **Звіт-порівняння** (≈ 2 год, після Q&A 26.10)

- Таблиця «модель × версія промпту × семплінг» з усіма метриками з кроку 2.
- Розбір 3–5 характерних помилок: що замість чого і чому.
- Фінальний вибір для продакшну в 1 абзаці + за яких умов ви б змінили рішення.

💡 **Для досвідчених (stretch, без додаткових балів):** третя модель (дешева провайдерська), автоматичний регресійний прогін промптів на golden set, кешування відповідей.

Вимоги, здача та терміни

Здаєте одне посилання на GitHub-репозиторій, який лектор чи ментор запускає однією командою.

Технічні вимоги

- Python 3.11+, будь-який провайдер (OpenAI, Anthropic, Gemini тощо) + локальна модель.
- Ключі — у `.env`, у репозиторій потрапляє лише `.env.example`.
- Запуск однією командою (`make run` або `python main.py`).
- Вартість старту: вистачає безкоштовних лімітів або до $5 на API; локальна модель має працювати на звичайному ноутбуці.

Що має бути в репозиторії

- код сервісу та схема;
- папка `prompts/` з версіями та changelog;
- `data/` з текстами та golden set;
- `results/` з виходами моделей;
- `REPORT.md` із звітом-порівнянням;
- `README.md`: як запустити і що потрібно встановити.

Терміни

Етап	Дата	Готовність
Старт	12.10	Заняття 1: вибір наскрізного проєкту
Чекпоінт	24.10	Кроки 1–2 в репозиторії, без балів
Q&A	26.10	Фідбек на чекпоінти, розбір типових помилок
Дедлайн	27.10, 23:59	Повна здача (кроки 1–4)
Перевірка	до 03.11	Оцінка за рубрикою + коментар до кожного знятого бала

📣 **Що НЕ потрібно:** UI, деплой, fine-tuning, великий датасет чи ідеальна точність — оцінюється інженерний підхід і чесні заміри.

⚠️ **Застрягли?** Питання — у чат курсу **#ai-engineering-2-questions** з тегом **#кейс1.** Якщо не встигаєте, скористайтеся заморозкою.

Критерії оцінювання (30 балів)

Найбільше балів дають кроки 2 і 3 — заміри та версіонування; за кожен знятий бал лектор чи ментор пише коментар.

Критерій	Бали
Крок 1. Схема і baseline	**6**
Схема відповідає вимогам (≥ 6 полів, enum, вкладена структура)	2
Structured output + retry і timeout	2
Усі тексти прогнані, результати збережені	2
Крок 2. Друга модель і заміри	**8**
Локальна модель через спільний інтерфейс	3
Семплінг у конфігу, ≥ 2 конфігурації порівняні	2
Коректні заміри точності, валідності, latency та вартості	3
Крок 3. Версіонування і валідація	**8**
≥ 2 версії промпту з changelog і поясненням змін	3
Валідація за схемою + обробка невалідних відповідей	3
Логування моделі, версії промпту та параметрів	2
Крок 4. Звіт-порівняння	**6**
Таблиця порівняння з усіма метриками	2
Розбір 3–5 помилок	2
Обґрунтований фінальний вибір	2
Якість репозиторію (README, запуск однією командою, ключі не в коді)	**2**
Разом	**30**